

Relatório de Pré-processamento e Classificação de Imagens Médicas

1. Introdução

Este relatório descreve as etapas de pré-processamento, treinamento e avaliação de modelos de Visão Computacional aplicados à classificação de imagens médicas, como parte do projeto Cardiola. O objetivo foi construir um protótipo de Assistente Cardiológico Virtual capaz de identificar padrões em raios-X de tórax, classificando-os como **Normal** ou **Doente**.

2. Dataset Utilizado

Foi utilizado o dataset público **NIH Chest X-rays** (amostra), disponível no Kaggle. O conjunto contém imagens de raio-X de tórax com rótulos de diagnóstico. Para simplificar o problema, os rótulos foram convertidos em uma classificação binária: **0 = Normal** (ausência de achados, "No Finding") e **1 = Doente** (qualquer patologia identificada).

A distribuição resultante foi de 3.044 imagens normais (54,3%) e 2.562 imagens de pacientes doentes (45,7%), caracterizando um dataset razoavelmente balanceado.

3. Pipeline de Pré-processamento

3.1 Redimensionamento e Normalização

Todas as imagens foram lidas em **escala de cinza**, pois raios-X de tórax são naturalmente monocromáticos e a conversão para RGB não agrega informação relevante nessa etapa. Em seguida, foram redimensionadas para **224×224 pixels**. Os valores de pixel foram normalizados para o intervalo **[0, 1]** dividindo por 255, o que estabiliza o treinamento e acelera a convergência.

3.2 Divisão do Dataset

- **Treino:** 70% — 3.923 imagens
- **Validação:** 15% — 842 imagens
- **Teste:** 15% — 841 imagens

3.3 Data Augmentation

Para o conjunto de treino, foi aplicado Data Augmentation com rotação leve (+/-5 graus), deslocamentos horizontais e verticais (5%) e zoom (5%).

4. Modelos Treinados

4.1 CNN do Zero

Foi implementada uma CNN simples com três blocos Conv2D + MaxPooling2D, seguidos de camadas densas com Dropout de 50% para regularização. O modelo foi treinado por até 15 épocas com Early Stopping monitorando o `val_loss` (paciência de 5 épocas), encerrando em 13 épocas.

A matriz de confusão revelou 370 verdadeiros negativos e 168 verdadeiros positivos, com 216 falsos negativos — indicando que o modelo teve dificuldade em identificar pacientes doentes.

4.2 Transfer Learning com ResNet50

Foi utilizado o modelo **ResNet50 pré-treinado no ImageNet**.

As imagens em escala de cinza foram convertidas para RGB (replicando o canal) e passadas pela função `preprocess_input` do ResNet50. O treinamento ocorreu por 10 épocas com Early Stopping

O ResNet50 superou a CNN do zero em todas as métricas, com redução dos falsos negativos de 216 para 173.

5. Protótipo de Interface

Foi desenvolvida uma interface interativa no Google Colab utilizando **ipywidgets**, permitindo que o usuário faça upload de uma imagem de raio-X e escolha entre os dois modelos para obter a classificação em tempo real. O resultado exibe o diagnóstico (Normal ou Doente), a probabilidade de cada classe em forma de barra visual e um aviso ético destacando que o sistema possui fins exclusivamente educacionais. O protótipo em funcionamento é demonstrado nas

6. Conclusão

O projeto demonstrou a viabilidade de aplicar técnicas de Visão Computacional na análise de imagens médicas. O uso de Transfer Learning com ResNet50 apresentou desempenho superior à CNN treinada do zero, evidenciando o ganho

obtido com modelos pré-treinados em grandes volumes de dados. Os resultados reforçam também a importância de métricas como Recall e F1-Score em aplicações médicas, onde minimizar falsos negativos é prioritário em relação à acurácia geral.